

卷积神经网络在结构损伤检测中的应用

罗雨舟， 向天宇， 郝柳青

(西华大学 土木建筑与环境学院,四川 成都 610039)

**摘 要:** 基于卷积神经网络(CNN)在损伤特征提取上的优势,本文开展了结构在不同激励类型作用下 CNN 损伤诊断精度的研究。通过有限元模拟试验,发现作用在结构上的激励类型不是影响 CNN 损伤识别精度的关键因素。同时,在测试 CNN 的抗噪能力并分析其特征提取的鲁棒性时,发现在不同噪声强度下 CNN 均取得了良好的识别效果。混合训练模式虽然对 CNN 识别精度有略微的影响,但却可以在一定程度上增强其识别稳定性。另外,在数值模拟试验中发现瞬态响应中包含了比稳态响应更为广阔的损伤特征,在输入数据中添加结构瞬态响应能够在一定程度上加快训练速率。

**关键词:** CNN; 结构损伤诊断; 激励类型; 识别精度

**中图分类号:** TU317<sup>+</sup>.1; TP206<sup>+</sup>.3      **文献标识码:** A      **文章编号:** 2095-0985(2020)03-0155-07

**Application of Convolutional Neural Network in Structural Damage Diagnosis**  
*LUO Yu-zhou, XIANG Tian-yu, HAO Liu-qing*  
(School of Civil Engineering, Architecture and Environment, Xihua University,  
Chengdu 610039, China)

**Abstract:** Based on the advantages of convolutional neural network (CNN) in extracting damage features, this paper studies the accuracy of CNN damage diagnosis under different excitation types. Through the finite element simulation test, it is found that the type of excitation on the structure is not the key factor affecting the accuracy of CNN damage identification. At the same time, when testing CNN's anti-noise ability and analyzing its robustness of feature extraction, it is found that CNN has achieved good recognition effect under different noise intensity. Although the hybrid training mode has a slight impact on CNN recognition accuracy, it can enhance its recognition stability to a certain extent. In addition, in the numerical simulation test, it is found that the transient response contains more extensive damage characteristics than the steady-state response. Adding the structure transient response to the input data can accelerate the training speed to a certain extent.

**Key words:** CNN; structural damage diagnosis; excitation type; recognition accuracy

土木工程结构在其使用寿命期间易在外力或介质的侵蚀下造成性能的劣化,从而导致安全性降低和经济损失,因此对结构进行健康检测很有必要。国内外学者在提取结构特征并将其运用于土木工程结构的实时监控方面都做出了巨大贡献,但距实际工程应用尚有距离<sup>[1]</sup>。对于传统的损伤检测方法,需先构建结构数学模型,随后使用

该模型阐明结构行为并建立损坏条件与结构响应之间的相关性<sup>[2]</sup>。但是,当检测遇到复杂的系统时,传统的损伤检测方法可能存在诸如测量噪声和建模误差等困难,并且该方法无法实现结构的实时损伤检测。在结构动力响应特性方面,尽管通过提取模态特征能够较为准确地判断结构的损伤状态<sup>[3,4]</sup>,并且能够实现结构的实时检测。但

收稿日期: 2019-07-08    修回日期: 2019-12-04  
作者简介: 罗雨舟(1995-),男,四川成都人,硕士研究生,研究方向为现代桥梁结构理论(Email: 975640121@qq.com)  
通讯作者: 向天宇(1972-),男,重庆万州人,博士,教授,研究方向为现代桥梁结构理论(Email: tyxiang.xhua@163.com)  
基金项目: 国家自然科学基金(51678030); 贵州省科技厅项目(黔科合支撑[2016]2047); 四川省教育厅科研项目(16TD0018)

是,不同温度和湿度条件下自振频率的变化<sup>[5]</sup>以及激励大小和类型的未知对该方法造成了一定的局限。与此同时,也有不少学者利用支持向量机、神经网络等机器学习算法进行损伤特征的提取和分类。但是,机器学习需要海量的训练样本,其需要学习的参数量巨大且容易出现过拟合现象<sup>[6]</sup>,因此该方法受到了极大限制。

近年来,深度学习在游戏博弈、图像识别以及无人驾驶等领域取得了非常成功的应用<sup>[7-9]</sup>,引起了不同学术领域对这一科学问题的广泛关注。卷积神经网络(Convolutional Neural Network, CNN)是深度学习中广泛应用的算法之一,其思想源于 Hubel 和 Wiesel<sup>[10]</sup>对动物视觉皮层细胞研究提出的感受野(Receptive Field)概念。到 1998 年,LeCun 等<sup>[11]</sup>提出了第一个正式的 CNN 模型 LeNet-5,如图 1 所示。相比于传统神经网络,卷积神经网络更类似于生物神经网络,采用局部连接和权值共享的网络结构,大大减少了所需训练参数的数量,在一定程度上降低了过拟合的可能。

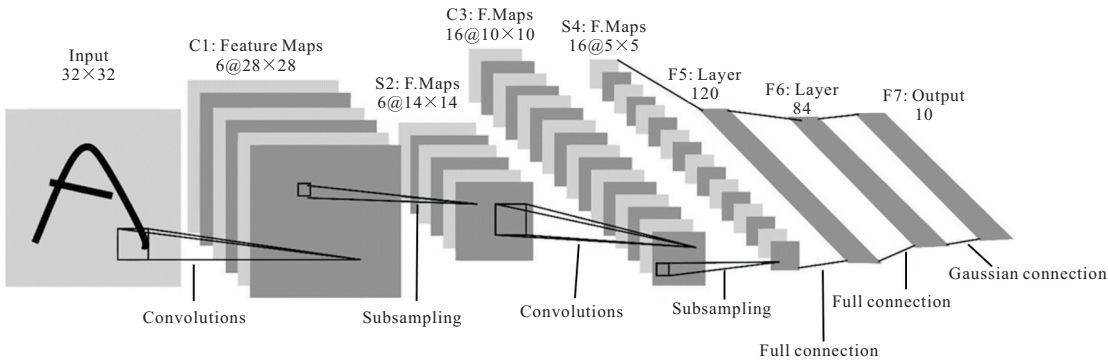


图 1 LeNet-5 结构

# 1 卷积神经网络

## 1.1 卷积神经网络的基本原理

一个完整的网络由输入层、卷积层、池化层、全连接层和输出层组成。以 LeNet-5 网络为例,它包括一个输入层,两个卷积层,两个池化层,两个全连接层和一个输出层。

CNN 的核心理论在于局部感受野。局部感受野的概念来自于生物神经科学,从直观上讲,局部感受野即视觉感受区域。如图 2 所示,生物神经科学已发现,在视觉认知过程中,通过对局部信息的提取加工得到更高层次的信息特征,即为局部感受野的概念。

## 1.2 卷积层

在卷积神经网络中,采用卷积层这一数学模型来模拟局部感受野这一神经科学现象。卷积层

因此,不少学者将 CNN 应用于结构损伤检测。Cha 等<sup>[12]</sup>利用 CNN 出色的图像识别能力,以混凝土裂缝图片作为输入,研究了 CNN 对混凝土结构裂缝等缺陷的图像识别精度。李雪松等<sup>[6]</sup>通过 CNN 提取结构加速度信号的特征向量,并且与小波包变化法和经验模态分解法做了系统对比,结果显示 CNN 自主提取的特征向量能更准确地反映结构的损伤情况。Abdeljaber 等<sup>[13,14]</sup>均采用了一维向量作为输入的卷积神经网络进行了结构损伤诊断的研究。Hoang 等<sup>[15]</sup>指出振动信号中包含了能反映损伤情况的丰富信息,因此将轴承振动信号转化成二维灰度图像,再利用 CNN 从中学习抽象的高级损伤特征,最后通过 Softmax 算法实现损伤的诊断。因此,受到上述学者研究成果的启发,本文拟采用结构在不同类型激励作用下的加速度时程信号作为输入,研究 CNN 在提取损伤特征过程中对激励类型的鲁棒性,并研究了 CNN 的抗噪能力。




图 2 局部感受野示意

的输入为上一网络层的输出,如图 3 所示,通过局部感受野对输入矩阵进行卷积操作,随后经过激活函数的激活形成该层网络的输出。

非线性激活从生物意义上可以理解当传递信号的值大于一个特定的阈值时,下个神经元才会被激活,否则抑制。在 CNN 中,其意义在于感受野提取到的某一个特征的特征强度是否达到一定标准。目前,如式(1)所示 ReLU 激活函数因其




图 3 卷积层

收敛速率快且能达到较高的精度而被广泛应用。

$$\text{ReLU}(x) = \max\{0, x\}$$
 (1)

式中:  $\max\{\cdot\}$  为最大值函数, 其返回值为括号中所有值的最大值, 即当  $x$  小于 0 时, ReLU 的值始终为 0; 当  $x$  大于 0 时, ReLU 的值始终与  $x$  相等。

总的来讲, 卷积层数学模型可以定义为:

$$x_j^l = f\left(\sum_{i=M_j} x_i^{l-1} \times k_{ij}^l + b_j^l\right)$$
 (2)

式中:  $\times$  表示卷积运算;  $M_j$  为输入特征图组合;  $l$  为第  $l$  层网络;  $k_{ij}^l$  为输入的第  $i$  个特征图和输出的第  $j$  个特征图连接的卷积核;  $x_j^l$  为第  $l$  层网络的输出;  $x_i^{l-1}$  为第  $l$  层网络的输入;  $f$  为激活函数;  $b_j^l$  为偏置项。

1.3 池化层

经过卷积层对信息的局部感知化后, 需要用池化层对信息进行压缩。池化方式一般分为两种, 最大值池化和均值池化。最大值池化是提取子矩阵中的最大值作为输出, 而均值池化是计算子矩阵的平均值作为池化结果, 如图 4 所示。池化层的主要目的是对卷积层中提取的特征进行汇总并对数据进行压缩, 从而使 CNN 能够抽取的特征范围更广。另外, 池化操作使模型更关注是否存在某种特征而非这些特征在哪里, 且在一定程度上防止过拟合。




图 4 下采样层

1.4 全连接层

在经过多次卷积池化处理后, 模型连接着 1 个及以上的全连接层, 如图 5 所示。




图 5 全连接层

与多层感知器类似, 全连接层中的每个神经元均与前层神经元连接, 其主要功能是整合卷积池化层中具有类别特征的信息。同时, 将卷积池化层中所提取到的特征信息映射到样本标记空间中, 实现对输入数据的分类, 因此全连接层在整个 CNN 中起到了分类器的作用, 其核心操作是如式 (3) 的线性变化。

$$y = Wx$$
 (3)

式中:  $x$  为该层的输入 (即前层的输出);  $y$  为该层的输出;  $W$  为权值。

1.5 Softmax 层

CNN 在经过多个卷积、池化操作和全连接层之后, 已经完成了输入信号的特征提取和压缩, 通过 Softmax 层实现对结构损伤的诊断。Softmax 是深度学习多分类问题中的核心算法, 其实质是一个概率表达式, 如式 (4) 所示。

$$p(y^{(i)} = j | x^{(i)}; \theta) = \frac{e^{\theta_j^T x^{(i)}}}{\sum_{k=1}^K e^{\theta_k^T x^{(i)}}}$$
 (4)

式中:  $i$  为  $m$  个训练集中第  $i$  个训练样本;  $j$  为  $n$  个分类标签中的第  $j$  个标签;  $\theta$  为权重;  $x^{(i)}$  为 Softmax 层的输入。

2 CNN 在损伤诊断中的应用

2.1 研究思路及方法流程

根据结构动力学原理可知, 结构振动具有一定的规律性, 并且主要表现在其振型上。对于损伤结构而言, 结构的振型中必然包含了能反应损伤的信息。因此通过提取振型中的损伤特征, 就能够实现对结构的损伤诊断。对于结构振型, 现阶段不能直接进行采集, 但是结构上多质点的振动规律能够反映出结构整体的振型。因此, 本文通过采集结构上多质点的加速度信号组成矩阵, 就能形成包含二维损伤特征的特征图作为网络的输入层。对于二维特征图提取, CNN 的局部感受野具有天生的优势。通过卷积层模型, 局部感受野实现对多通道信号特征的提取, 这样也就能在一定程度上得到了更广阔的损伤信息。

基于上述分析, 本文通过有限元软件, 模拟了随机损伤的简单结构, 提取结构在不同类型激励作用下的加速度时程信号作为 CNN 的输入。图 6 展示了该方法的基本流程, 首先通过数值模拟试验提取结构多点加速度信号组成矩阵, 随后搭建 CNN 模型对该加速度矩阵进行特征提取并实现损伤诊断, 最后通过预测集对模型进行测试, 计算其识别精度。




图 6 本文方法流程

2.2 CNN 架构

CNN 超参数的选择是一项十分繁琐的工作,且目前对于这些参数的优化尚未有明确的指导原则。因此,本文通过反复试验探索结构损伤诊断的最优架构。首先为确定 CNN 架构超参数,本文进行了大量试验,在保持迭代次数、卷积核尺寸及个数不变的条件下,研究了 CNN 的最高识别精度,如图 7 所示。随后控制卷积池化层数不变,研究了卷积核个数的影响。根据图示结果并综合计算时间成本,本文推荐的卷积层数量为 2~3 个。对于卷积核,尺寸上本文采用 3×3,第一卷积层推荐采用 3~4 个,第二、三卷积层推荐 6~8 个。




图 7 不同卷积层数的分类结果

此外,分类的准确率会受迭代次数的影响,图 8 展示了不同迭代次数下的 CNN 平均识别准确率。因此本文推荐采用的迭代次数为 5000~6000。

本文 CNN 基本架构如图 9 所示,第一层是大小为 4×160 的输入层,其中两个维度分别代表采




图 8 不同迭代次数的分类结果

样通道和采样数,随后每层节点数量均在图 9 中通过数字表示。在卷积操作 C1~C2 中均采用 ReLU 函数作为激活函数,池化层则采用最大值池化。在全连接操作中,L5~L7 层采用 Sigmoid 激活函数,最后通过 Softmax 函数实现分类。由于 Softmax 的输出数据为输入样本在每个类别标签上的概率分布,因此为保证分类的准确性,选择分类正确概率超过 60% 的样本进行分类准确率的计算。整个模型的搭建和优化均在 TensorFlow 环境下进行,并选用梯度下降优化器,其实现代码为: `train_step = tf.train.GradientDescentOptimizer(learning_rate).minimize(cross_entropy)` (tf 为 Python 语言下 TensorFlow 的缩写;train 为调用命令的名称;GradientDescentOptimizer 为选择使用梯度下降优化器;learning\_rate 为学习速率,本文学习速率为 0.00001;minimize(cross\_entropy) 为使交叉熵最小化)。

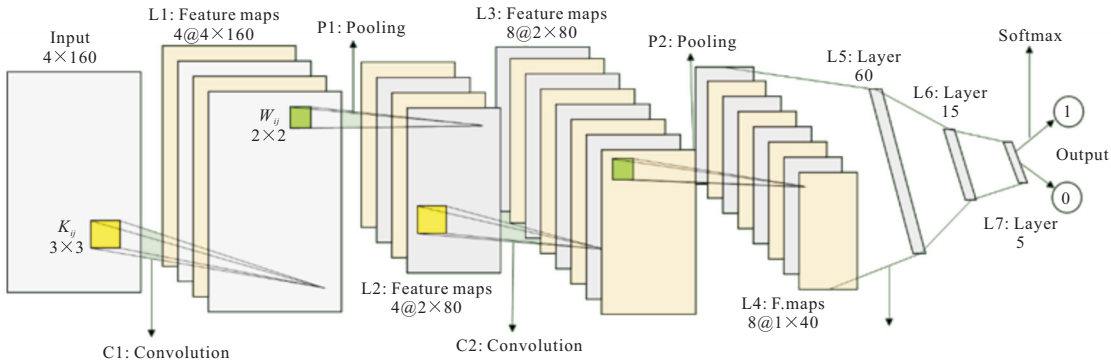


图 9 CNN 架构

3 数值试验

3.1 竖直悬臂梁模型

为研究激励类型对识别精度的影响规律和

CNN 特征提取的鲁棒性,本文利用 ANSYS 有限元软件建立了一个如图 10 所示的竖直悬臂梁模型。以下为本模型的基本参数:悬臂梁模型总共分为 4 个梁单元,以每个单元上部的节点作为采样点,由下而上分别编为 1~4 号。模型总高 2.4



m,每个单元长 0.6 m,弹性模量  $E = 2.06 \times 10^{11}$  N/m<sup>2</sup>,截面面积为 14.33 cm<sup>2</sup>,惯性矩  $I = 243.98$  cm<sup>4</sup>。结构的损伤通过折减单元的刚度模拟,即在原模型定义刚度  $EI$  上乘折减系数  $\delta$  ( $\delta$  是大小在 0.5~1 上的随机数,其中 0.5 表示刚度损失一半,1 表示刚度未损失),形成  $\delta EI$ 。所有单元均设置损伤,因此每个样本中包含 4 个随机的刚度折减系数  $\delta_1 \sim \delta_4$ 。

为研究不同激励作用下 CNN 的识别精度,本文分别将随机的正弦激励、风激励以及白噪声激励作用到模型上。所有激励均是通过 MATLAB 软件随机生成,对于正弦激励,其振幅和频率均是服从正态分布的随机数。白噪声激励为满足正态分布的随机数。风激励则是根据 Davenport 风谱生成风速时程曲线,通过随机风速计算得到的随机风压,如式(5)所示。

$$w_p = \frac{1}{2} \rho v^2$$

(5)

式中:  $w_p$  为风压;  $\rho$  为空气密度,其值取 1.29 kg/m<sup>3</sup>;  $v$  为风速。

此外,激励的加载方式有所不同,正弦激励以




图 11 数据集中的加速度信号(每个信号尺寸为 4×160)

由于在实际情况下采集的振动信号是带噪的,为研究 CNN 的抗噪能力,本文进行了 CNN 抗噪性的仿真试验,根据式(6)所示信噪比对原始信号进行加噪,信噪比(Signal Noise Ratio, SNR)定义为:

$$SNR = \frac{\text{信号能量}}{\text{噪声能量}} = \frac{\text{纯信号}^2}{(\text{带噪信号} - \text{纯信号})^2}$$

(6)

3.2 结果分析

(1)在单激励无噪声训练模式下(即训练集中只有单一激励产生的加速度信号并且未加噪),平均识别精度均稳定在 90% 以上,如图 12a 所示。采用混合激励训练模式(即训练集中混合各种激励产生的加速度信号的训练模式)时,CNN 对正弦激励和风激励作用下结构损伤的识别精度没有明显影响。但是对白噪声激励作用下的平均识别精度有 2% 的提高,因此其平均识别率基本

集中力的形式作用在悬臂梁的顶端。风激励和白噪声激励则以均布荷载的形式作用在梁体上,如图 10 所示。




图 10 竖直悬臂梁模型

通过上述操作,每个样本都是由不同大小、不同类型的激励作用生成的。每种激励生成 2000 个正常样本和 2000 个损伤样本作为 CNN 的训练集,另外生成相同数量的正常和损伤样本作为 CNN 的预测集。每个样本采集了悬臂梁模型上 4 个节点的加速度时程信号,采样时间为 3.2 s,采样频率是 50 Hz,因此将得到 4×160 的样本矩阵,如图 11 所示为不同激励作用下的加速度响应时程曲线。

稳定在 95% 左右。具体情况如图 12b 所示。由此可见,虽然结构在不同激励作用下的各点加速度响应有明显差异(如图 11 所示),但是这种差异不会影响到 CNN 对其损伤特征的提取,不同类型的激励及加载方式对 CNN 识别精度没有明显影响,且在采用混合激励训练模式后,相比于单激励训练模式,CNN 的识别稳定性有一定的提高,其详细平均识别精度如表 1 所示。




图 12 不同训练模式下的 CNN 识别精度

表 1 CNN 平均识别精度

训练模式	激励类型	识别精度/%
单激励训练模式	正弦激励	96
	风激励	95
	白噪声激励	93
混合激励训练模式	正弦激励	96
	风激励	95
	白噪声激励	95

(2)如图 13a 所示,结构受正弦激励作用时,低强度噪声( $SNR=10$ )对 CNN 的识别精度影响较小,基本可以忽略,其识别率均在 95%以上,平均值为 96%。随着噪声强度的增加,即当噪声强度增大到信噪比为 5 时,CNN 的识别率受到较大影响,但也基本稳定在 92%左右。当在添加了与加速度时程信号等能量强度,即  $SNR=1$  的噪声之后,CNN 的平均识别准确率下滑到 86%。可见,CNN 对正弦激励作用下结构的损伤识别率呈现出线性下滑的态势。当结构受到风激励作用时,CNN 的带噪识别精度如图 13b 所示。从图中可以看出,当  $SNR=10$  和 5 时,CNN 的识别精度未受到显著影响,平均识别率从 95%下降到 92%。但是当噪声强度进一步升高到  $SNR=1$  时,其识别率出现了显著下降,但是其平均精度仍然保持在 83%左右,其识别精度依旧令人满意,详细数据如表 2 所示。对于白噪声激励作用下结构的加速度信号其本身便可理解成噪声,因此本文在这里并未对其进行加噪研究。综上,在不同强度白噪声的作用下,CNN 展现出了良好的抗噪能力,并且不同的激励类型对 CNN 的识别率没有明显影响。此外,CNN 对不同激励之间的识别率虽略有差异,但是总体上均在可接受范围内,所以激励类型不是影响 CNN 识别精度的关键因素。




图 13 CNN 的带噪识别精度

表 2 CNN 带噪识别精度

激励类型	信噪比	识别精度/%
正弦激励	10	96
	5	91
	1	86
风激励	10	95
	5	92
	1	84

(3)根据文献[6]的研究结果可知,混噪训练模式(即以不同强度噪声作为 CNN 的训练数据)可以有效地提高 CNN 的噪声容错区间,并且能更好地表达结构信息。如图 14 所示,采用混噪数据训练的 CNN 模型在整体识别率上高于单一噪声训练的模型,这也在一定程度上验证了文献[6]的结论。此外,通过混合训练模式(即混激励和混噪模式的结合,训练集中既包含了不同激励类型也包含了不同强度噪声)训练 CNN,其平均准确率如图 15 所示。对比图 14,发现相较于单一激励训练模式,混合训练的 CNN 识别率出现了小范围下滑,整体水平仍保持在 90%左右。另外,在单激励训练模式下,随噪声强度的增加出现的识别率较大程度下滑,在混合激励训练模式下并未出现,可见通过混合激励训练模式,CNN 模型的鲁棒性和稳定性在一定程度上得到了增强。其详细准确率数据如表 3 所示。




图 14 混噪训练模式下 CNN 的识别精度




图 15 混合训练模式下 CNN 的识别精度

表 3 不同训练模式下 CNN 带噪识别精度

训练模式	激励类型	信噪比	识别精度/%
混合噪声训练模式	正弦激励	10	95
		5	93
		1	90
	风激励	10	94
		5	92
		1	91
混合训练模式	正弦激励	10	93
		5	91
		1	88
	风激励	10	92
		5	91
		1	89

(4)通过将瞬态响应和稳态响应分开训练,发现瞬态响应中应包含更为广阔的损伤特征信

息。在激励作用下,由结构动力学原理可知,结构振动分为瞬态响应和稳态响应两种阶段。但因为阻尼的存在,瞬态响应会很快衰减,最终只呈现出稳态响应,如图 16 所示,虚线框内为瞬态响应,实线框内为稳态响应。




图 16 正弦激励下结构加速度响应

因此,分别将带有瞬态响应的信号和不带瞬态响应的信号作为输入训练 CNN。结果如图 17 所示,在迭代步同为 2000 时,有瞬态响应信号的网络识别率已经非常可观,平均精度稳定在 96%,而不带瞬态信号的网络识别率仅仅为 68%。但是当迭代步数为 6000 时,后者识别率依然可以达到 93%。




图 17 不同训练阶段准确率

4 结 论

本文建立了一个简化的结构有限元模型,利用 CNN 在二维信号处理上的独特优势对 4 点的加速度信号进行自动特征提取并分类。研究发现,虽然在不同类型激励作用下,CNN 的识别精度略有不同,但是整体来讲对 CNN 的识别准确率没有明显影响。并且,混激励训练可以在一定程度上提高 CNN 对不同激励的识别稳定性。因此,激励的类型不是影响 CNN 识别精度的主要因素。

在单激励训练模式下,CNN 表现出了良好的抗噪性,但是对于不同噪声强度,其稳定性相对较差。采用混噪训练模式后,CNN 的识别稳定性有了较为明显的改善。采用混合训练模式时,发现 CNN 的识别精度相较于混噪训练模式出现了小幅下降,但是其稳定性得到了提升,总体上识别率均稳定在 90%左右。

此外,相较于稳态响应,瞬态响应包含了更广阔的损伤特征,而 CNN 可以对这些特征进行有效

提取。并且在训练集中加入瞬态响应可以使网络的训练速率加快。另外,尽管稳态响应中包含的特征不如瞬态响应广阔,但是同样可以有效反应结构的损伤情况。

目前,CNN 对结构的损伤诊断尚处于起步阶段,对用于诊断结构损伤的 CNN 架构及其参数设计仍是一个较大的挑战,目前只能通过试验验证法确定,因此本文所选取的超参数未必为最优参数。但是,从上述结果来看,CNN 在结构损伤诊断方面的应用还大有可为之处。

参 考 文 献

[1] 马宏伟, 聂振华. 桥梁安全监测最新研究进展与思考[J]. 力学与实践, 2015, 37(2): 161-170.

[2] Kao C Y, Hung S L. Detection of structural damage via free vibration responses generated by approximating artificial neural networks[J]. Computers and Structures, 2003, 81: 2631-2644.

[3] 赵 俊, 程良彦, 马宏伟. 基于曲率模态的拱板结构损伤识别[J]. 暨南大学学报( 自然科学与医学版), 2008, 29(5): 470-477.

[4] 聂振华, 程良彦, 马宏伟. 基于结构动力特性的损伤检测可视化方法[J]. 振动与冲击, 2011, 30(12): 7-13.

[5] Peeters B, Roeck G D. One-year monitoring of the Z24-Bridge: environmental effects versus damage events[J]. Earthquake Engineering & Structural Dynamics, 2001, 30(2): 149-171.

[6] 李雪松, 马宏伟, 林逸周. 基于卷积神经网络的结构损伤识[J]. 振动与冲击, 2019, 38(1): 159-167.

[7] David Silver, Julian Schrittwieser, Karen Simonyan, et al. Mastering the game of Go without human knowledge[J]. Nature, 2017, 550: 354-359.

[8] 王 博, 郭继昌, 张 艳. 基于深度网络的可学习感受野算法在图像分类中的应用[J]. 控制理论与应用, 2015, 32(8): 1114-1119.

[9] 王科俊, 赵彦东, 邢向磊. 深度学习在无人驾驶汽车领域应用的研究进展[J]. 智能系统学报, 2018, 13(1): 55-69.

[10] Hubel D H, Wiesel T N. Receptive fields and functional architecture of monkey striate cortex[J]. The Journal of Physiology, 1968, 195: 215-243.

[11] Lecun Y, Bottou L, Bengio Y, et al. Gradient-based learning applied to document recognition[J]. Proceedings of the IEEE, 1998, 86(11): 2278-2324.

[12] Cha Y, Choi W, Büyüköztürk O, et al. Deep learning-based crack damage detection using convolutional neural networks[J]. Computer-Aided Civil and Infrastructure Engineering, 2017, 32: 361-378.

[9] 孙 彬,毛诗洋,王 霓,等. 预成孔法检测装配式结构套筒灌浆饱满度的试验研究[J]. 建筑结构, 2018, 48(23): 7-10.

[10] 李向民,高润东,许清风,等. 灌浆缺陷对钢筋套筒灌浆连接接头强度影响的试验研究[J]. 建筑结构, 2018, 48(7): 52-56.

[11] 高润东,李向民,许清风. 装配整体式混凝土建筑套筒灌浆存在问题与解决策略[J]. 施工技术, 2018, 47(10): 1-4.

[12] 郭正兴,颜 文. 装配式混凝土结构套筒灌浆连接灌浆料饱满度试验研究[J]. 江苏建筑, 2018,(3): 4-8.

(上接第 140 页)

[9] 秦顺全. 斜拉桥安装无应力状态控制法[J]. 桥梁建设, 2003, (2): 31-34.

[10] 王 桢,罗 波,吴海军,等. 大跨径自锚式悬索桥几何非线性行为分析[J]. 重庆交通大学学报(自然科学版), 2015, 34(2): 1-6.

[11] Jung M R, Min D J, Kim M Y. Nonlinear analysis methods based on the unstrained element length for determining initial shaping of suspension bridges under dead loads[J]. Computers and Structures, 2013, 128: 272-285.

(上接第 146 页)

[5] JTG/T B02-01—2008, 公路桥梁抗震设计细则[S].

[6] 李小珍,洪沁烨,雷虎军,等. 地震动输入方向对铁路部分斜拉桥地震响应的影响[J]. 桥梁建设, 2015, 45(1): 26-32.

[7] 孙佳音. 近断层地震动输入方向对刚构桥地震反应影响[D]. 大连: 大连海事大学, 2017.

[8] 顾红飞. 斜交箱梁桥地震响应特性分析[D]. 成都: 西南交通大学, 2011.

[9] 廖 兴. 斜交连续梁桥地震反应分析[D]. 北京: 北京交通大学, 2011.

[10] 郭劭钦. 基于不同输入方向的斜交桥最不利地震动响应研究[D]. 北京: 北京交通大学, 2014.

[11] Deepu S P, Prajapat K, Ray-Chaudhuri S. Seismic vulnerability of skew bridges under bi-directional ground motions [J]. Engineering Structures, 2014, 71: 150-160.

[12] Han Q, Chen J Y, Du X L, et al. Nonlinear seismic response of skewed highway bridges subjected to bidirectional near-fault ground motions [J]. Journal of Bridge Engineering, 2017, 22(7): 04017032-1-14.

[13] Maleki S, Bisadi V. Orthogonal effects in seismic analysis of skewed bridges[J]. Journal of Bridge Engineering, 2006, 11(1): 122-130.

[14] Bisadi V, Head M. Evaluation of combination rules for orthogonal seismic demands in nonlinear time history analysis of bridges[J]. Journal of Bridge Engineering, 2011, 16(6): 711-717.

[15] 项海帆. 高等桥梁结构理论(第二版)[M]. 北京: 人民交通出版社, 2013.

[16] 王军文,湛 敏,邓 琴,等. 三跨斜交简支梁桥地震旋转机理及斜度影响研究[J]. 哈尔滨工程大学学报, 2018, 39(8): 1357-1362.

[17] Xiang N L, Li J Z. Effect of exterior concrete shear keys on the seismic performance of laminated rubber bearing-supported highway bridges in China[J]. Soil Dynamics and Earthquake Engineering, 2018, 112: 185-197.

(上接第 161 页)

[13] Abdeljaber O, Avci O, Kiranyaz M S, et al. 1-D CNNs for structural damage detection: verification on a structural health monitoring benchmark data[J]. Neurocomputing, 2018, 275: 1308-1317.

[14] Abdeljaber O, Avci O, Kiranyaz S, et al. Real-time vibration-based structural damage detection using one-dimensional convolutional neural networks[J]. Journal of Sound and Vibration, 2017, 388: 154-170.

[15] Hoang D T, Kang H J. Rolling element bearing fault diagnosis using convolutional neural network and vibration image[J]. Cognitive Systems Research, 2019, 53: 42-50.